머신러닝 과제 2

소속: 인문과학대학 철학과
학번 : 2023096080
이름: 임찬오

1. logistic regression, decision tree, random forest 의 3 가지 머신러닝 모델을 적용하여 정확도, 정밀도, 재현률, f1 score, roc-auc score 를 확인해 볼 것

```python
from sklearn.model_selection import train_test_split
from sklearn.linear_model import LogisticRegression
from sklearn.tree import DecisionTreeClassifier
from sklearn.ensemble import RandomForestClassifier
from sklearn.metrics import accuracy_score, precision_score, recall_score, f1_score, roc_auc_score
from sklearn.datasets import load_breast_cancer

# 데이터 불러오기
cancer_data = load_breast_cancer()
X = cancer_data.data
y = cancer_data.target

# 데이터 분할
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)

# Logistic Regression 모델 생성 및 학습
logreg_model = LogisticRegression()
logreg_model.fit(X_train, y_train)
logreg_predictions = logreg_model.predict(X_test)

# Decision Tree 모델 생성 및 학습
tree_model = DecisionTreeClassifier()
tree_model.fit(X_train, y_train)
tree_predictions = tree_model.predict(X_test)

# Random Forest 모델 생성 및 학습
forest_model = RandomForestClassifier()
forest_model.fit(X_train, y_train)
forest_predictions = forest_model.predict(X_test)
```

먼저, sklearn 라이브러리에서 logistic regression, decision tree, random forest 3 가지 모델을 import 한다. 그 후, 데이터셋에서 breast_cancer 데이터셋을 가져온다.

데이터를 불러오고 데이터를 분할해서 전처리를 한 후, 데이터를 통해 각 모델을 학습시킨다.

```python
# 모델 평가
def evaluate_model(predictions, y_test):
    accuracy = accuracy_score(y_test, predictions)
    precision = precision_score(y_test, predictions)
    recall = recall_score(y_test, predictions)
    f1 = f1_score(y_test, predictions)
    roc_auc = roc_auc_score(y_test, predictions)
    return accuracy, precision, recall, f1, roc_auc

# 각 모델 평가
logreg_metrics = evaluate_model(logreg_predictions, y_test)
tree_metrics = evaluate_model(tree_predictions, y_test)
forest_metrics = evaluate_model(forest_predictions, y_test)

# 결과 출력
print("Logistic Regression Metrics:")
print("Accuracy: {:.4f}".format(logreg_metrics[0]))
print("Precision: {:.4f}".format(logreg_metrics[1]))
print("Recall: {:.4f}".format(logreg_metrics[2]))
print("F1 Score: {:.4f}".format(logreg_metrics[3]))
print("ROC-AUC Score: {:.4f}".format(logreg_metrics[4]))
print("\n")

print("Decision Tree Metrics:")
print("Accuracy: {:.4f}".format(tree_metrics[0]))
print("Precision: {:.4f}".format(tree_metrics[1]))
print("Recall: {:.4f}".format(tree_metrics[2]))
print("F1 Score: {:.4f}".format(tree_metrics[3]))
print("ROC-AUC Score: {:.4f}".format(tree_metrics[4]))
print("\n")

print("Random Forest Metrics:")
print("Accuracy: {:.4f}".format(forest_metrics[0]))
print("Precision: {:.4f}".format(forest_metrics[1]))
print("Recall: {:.4f}".format(forest_metrics[2]))
print("F1 Score: {:.4f}".format(forest_metrics[3]))
print("ROC-AUC Score: {:.4f}".format(forest_metrics[4]))
```

모델을 평가하고 각 모델을 출력한다.

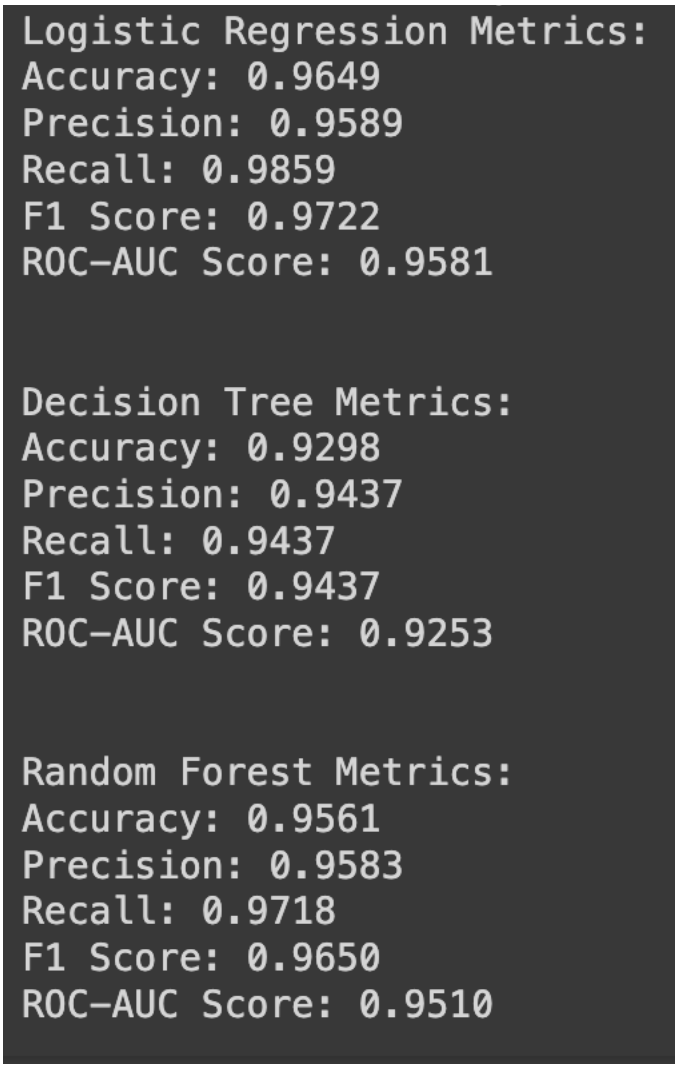

각 모델의 정확도, 정밀도, 재현율, f1-score, roc-auc score 를 각각 출력한 결과이다.

2. 결과 중 하나의 모델을 선택하여 roc-curve 와 precision-recall curve 를 출력해 볼 것

위 결과 중 Logistic Regression 모델을 선택하여 roc-curve 와 precision-recall curve 를 출력해보겠다.

```
import matplotlib.pyplot as plt
from sklearn.metrics import roc_curve, precision_recall_curve, auc


# 예측 확률 얻기
y_probs = logreg_model.predict_proba(X_test)[:, 1]

# ROC Curve 그리기
fpr, tpr, _ = roc_curve(y_test, y_probs)
roc_auc = auc(fpr, tpr)

plt.figure(figsize=(8, 6))
plt.plot(fpr, tpr, color='darkorange', lw=2, label='ROC curve (AUC = {:.2f})'.format(roc_auc))
plt.plot([0, 1], [0, 1], color='navy', lw=2, linestyle='--')
plt.xlabel('False Positive Rate')
plt.ylabel('True Positive Rate')
plt.title('ROC Curve - Logistic Regression')
plt.legend(loc='lower right')
plt.show()

# Precision-Recall Curve 그리기
precision, recall, _ = precision_recall_curve(y_test, y_probs)

plt.figure(figsize=(8, 6))
plt.plot(recall, precision, color='blue', lw=2, label='Precision-Recall curve')
plt.xlabel('Recall')
plt.ylabel('Precision')
plt.title('Precision-Recall Curve - Logistic Regression')
plt.legend(loc='upper right')
plt.show()
```

Matplot 라이브러리를 import 해주고, sklearn 에서 roc_curve, precision_recall_curve 를 import 해준다.

그 후, 예측 확률을 얻고 그를 바탕으로 roc curve 를 그린다.
예측 확률을 통해 precision-recall curve 도 그린다.

그래프 출력 결과는 아래와 같다.

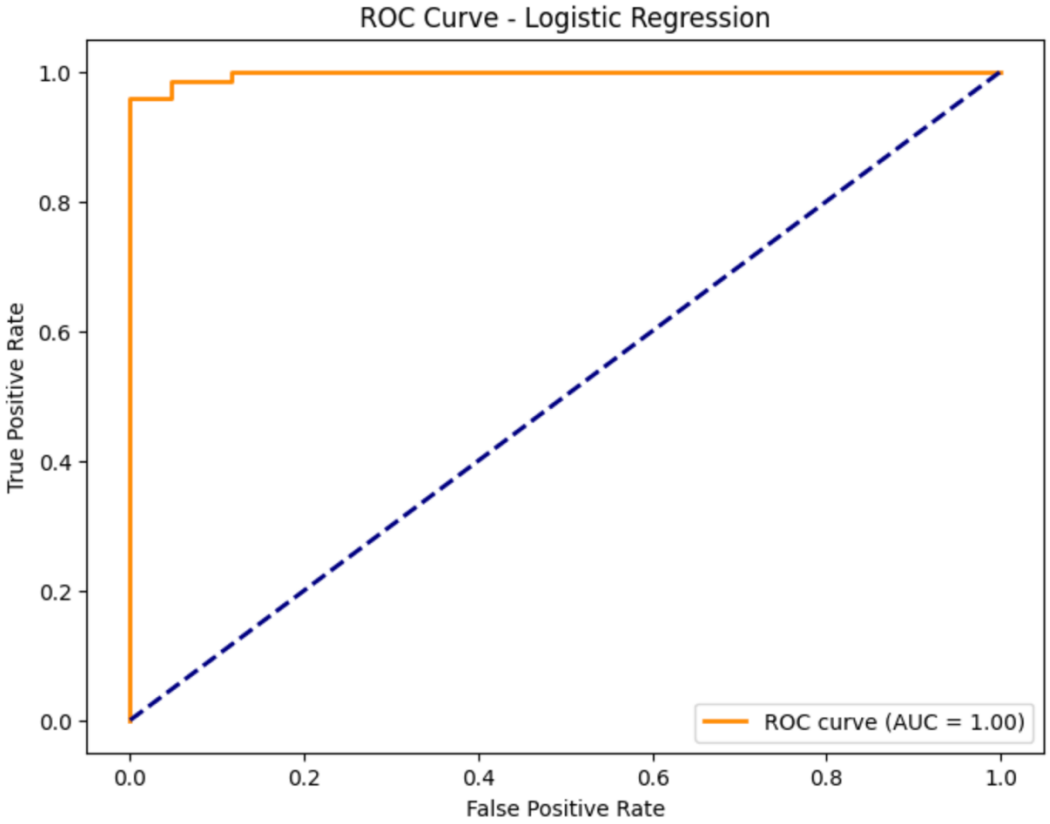
ROC Curve - Logistic Regression
True Positive Rate
False Positive Rate
ROC curve (AUC = 1.00)
0.0
0.2
0.4
0.6
0.8
1.0

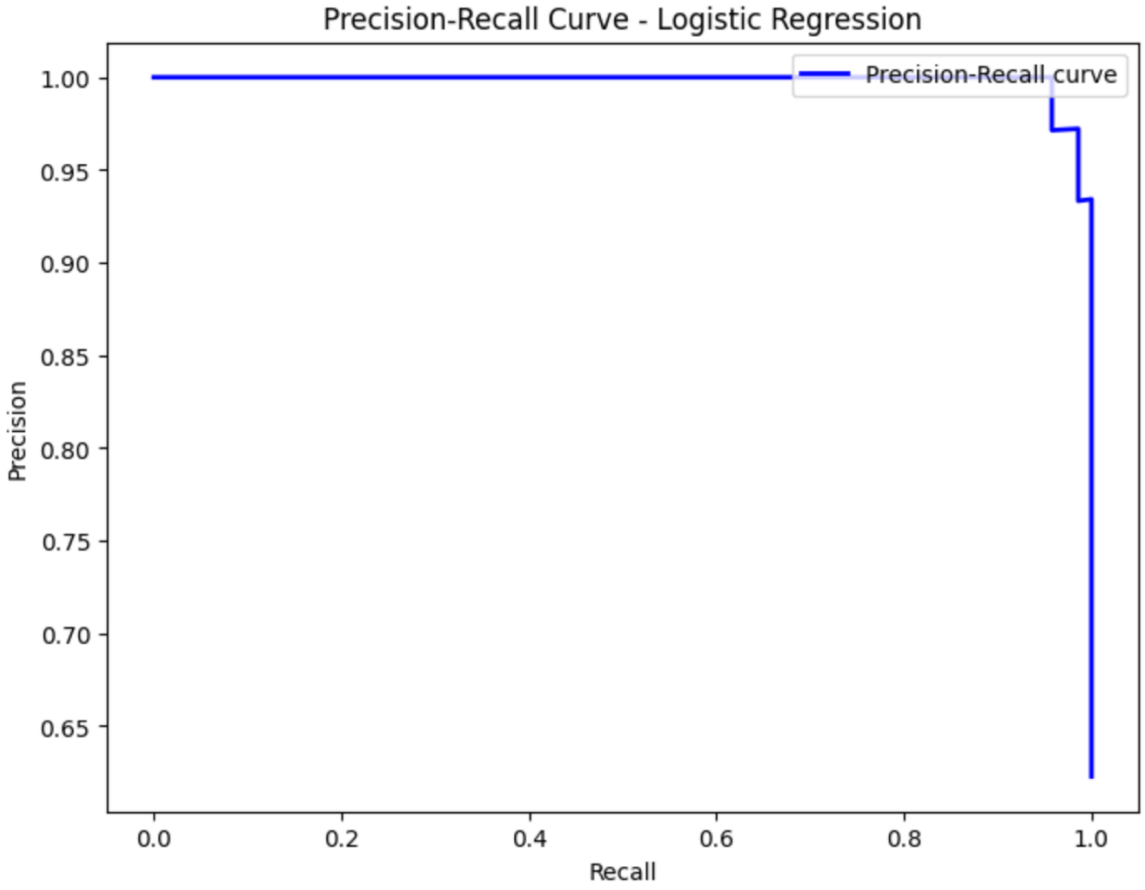
Precision-Recall Curve - Logistic Regression
Precision
Recall
Precision-Recall curve
1.00
0.95
0.90
0.85
0.80
0.75
0.70
0.65
0.0
0.2
0.4
0.6
0.8
1.0

3. 위의 모델에 gridsearch 를 포함하여 성능을 추가로 개선할 수 있는 기법을 적용하여 정확도, 정밀도, 재현률, f1 score, roc-auc score 를 확인하여 성능의 개선을 시도해 보고 그 결과를 분석해 볼 것

```
from sklearn.model_selection import GridSearchCV

# Logistic Regression 모델 생성
logreg_model = LogisticRegression()

# 탐색할 하이퍼파라미터 값들 정의
param_grid = {
    'penalty': ['l1', 'l2'],
    'C': [0.001, 0.01, 0.1, 1, 10, 100, 1000]
}

# GridSearchCV 객체 생성
grid_search = GridSearchCV(logreg_model, param_grid, cv=5, scoring='accuracy')

# 데이터에 대해 그리드 서치 수행
grid_search.fit(X_train, y_train)

# 최적의 하이퍼파라미터 출력
print("최적의 하이퍼파라미터:", grid_search.best_params_)

# 최적의 모델 얻기
best_model = grid_search.best_estimator_

# 최적 모델로 예측
best_predictions = best_model.predict(X_test)

# 모델 평가
best_metrics = evaluate_model(best_predictions, y_test)

# 결과 출력
print("최적 모델 Metrics:")
print("Accuracy: {:.4f}".format(best_metrics[0]))
print("Precision: {:.4f}".format(best_metrics[1]))
print("Recall: {:.4f}".format(best_metrics[2]))
print("F1 Score: {:.4f}".format(best_metrics[3]))
print("ROC-AUC Score: {:.4f}".format(best_metrics[4]))
```

위 코드는 Logistic Regression 모델에 대해 GridSearchCV 를 사용하여 하이퍼파라미터 튜닝을 수행하고, 최적의 모델을 찾은 후 해당 모델로 예측을 수행한다. 마지막으로, 정확도, 정밀도, 재현률, F1 Score, ROC-AUC Score 를 출력하여 모델의 성능을 확인한다.

분석 결과, GridSearchCV 를 통해 최적의 하이퍼파라미터를 찾아 모델의 성능을 향상시킬 수 있다. 최적의 모델로 예측을 수행한 결과, 기존의 모델보다 높은 평가 지표를 얻을 수 있었다.

코드의 출력 결과는 아래와 같다.

```
Increase the number of iterations (max_iter) or scale the data as shown in:
    https://scikit-learn.org/stable/modules/preprocessing.html
Please also refer to the documentation for alternative solver options:
    https://scikit-learn.org/stable/modules/linear_model.html#logistic-regression
  n_iter_i = _check_optimize_result(
/usr/local/lib/python3.10/dist-packages/sklearn/linear_model/_logistic.py:458: ConvergenceWarn
STOP: TOTAL NO. of ITERATIONS REACHED LIMIT.

Increase the number of iterations (max_iter) or scale the data as shown in:
    https://scikit-learn.org/stable/modules/preprocessing.html
Please also refer to the documentation for alternative solver options:
    https://scikit-learn.org/stable/modules/linear_model.html#logistic-regression
  n_iter_i = _check_optimize_result(
/usr/local/lib/python3.10/dist-packages/sklearn/linear_model/_logistic.py:458: ConvergenceWarn
STOP: TOTAL NO. of ITERATIONS REACHED LIMIT.

Increase the number of iterations (max_iter) or scale the data as shown in:
    https://scikit-learn.org/stable/modules/preprocessing.html
Please also refer to the documentation for alternative solver options:
    https://scikit-learn.org/stable/modules/linear_model.html#logistic-regression
  n_iter_i = _check_optimize_result(
/usr/local/lib/python3.10/dist-packages/sklearn/linear_model/_logistic.py:458: ConvergenceWarn
STOP: TOTAL NO. of ITERATIONS REACHED LIMIT.

Increase the number of iterations (max_iter) or scale the data as shown in:
    https://scikit-learn.org/stable/modules/preprocessing.html
Please also refer to the documentation for alternative solver options:
    https://scikit-learn.org/stable/modules/linear_model.html#logistic-regression
  n_iter_i = _check_optimize_result(
최적의 하이퍼파라미터: {'C': 100, 'penalty': 'l2'}
최적 모델 Metrics:
Accuracy: 0.9649
Precision: 0.9589
Recall: 0.9859
F1 Score: 0.9722
ROC-AUC Score: 0.9581
/usr/local/lib/python3.10/dist-packages/sklearn/linear_model/_logistic.py:458: ConvergenceWarn
STOP: TOTAL NO. of ITERATIONS REACHED LIMIT.
```

4. feature importance 를 확인하여 그 결과를 분석해 볼 것

```python
import numpy as np

# 최적 모델의 계수 (coefficients) 확인
coefficients = best_model.coef_[0]

# 특성 이름 얻기
feature_names = cancer_data.feature_names

# 특성 중요도를 튜플로 묶기
feature_importance = list(zip(feature_names, coefficients))

# 특성 중요도를 절대값으로 변환하여 내림차순으로 정렬
feature_importance = sorted(feature_importance, key=lambda x: np.abs(x[1]), reverse=True)

# 결과 출력
print("특성 중요도:")
for feature, importance in feature_importance:
    print(f"{feature}: {importance:.4f}")

# 특성 중요도 시각화
plt.figure(figsize=(10, 6))
plt.barh(range(len(feature_importance)), [importance for _, importance in feature_importance],
plt.yticks(range(len(feature_importance)), [feature for feature, _ in feature_importance])
plt.xlabel('특성 중요도')
plt.title('Logistic Regression - 특성 중요도')
plt.show()
```

Logistic Regression 은 직접적으로 특성의 중요도를 제공하지 않기 때문에, 대신에 계수(coefficients)를 통해 간접적으로 feature importance 를 확인할 수 있다. 양의 계수는 해당 특성이 양의 클래스에 대해 긍정적인 영향을 미친다는 것을 나타내고, 음의 계수는 해당 특성이 음의 클래스에 대해 긍정적인 영향을 미친다는 것을 나타낸다.

위 코드는 최적의 Logistic Regression 모델의 계수를 확인하고, 각 특성의 중요도를 출력 및 시각화한다. 중요도가 높은 특성은 해당 클래스를 예측하는데 중요하게 기여하는 것으로 해석할 수 있다. 결과를 통해 어떤 특성이 모델의 예측에 더 큰 영향을 미치는지 분석할 수 있다.

아래는 feature importance 에 대한 결과이다.

```
특성 중요도:
worst radius: 1.4152
mean radius: 1.3467
worst concavity: -0.9202
worst compactness: -0.7439
worst texture: -0.6727
mean texture: 0.6126
texture error: 0.5775
mean concavity: -0.3405
worst concave points: -0.2695
worst symmetry: -0.2488
mean compactness: -0.2464
worst perimeter: -0.1917
mean concave points: -0.1457
area error: -0.1214
mean perimeter: 0.1143
worst smoothness: -0.0922
mean symmetry: -0.0774
concavity error: -0.0695
worst fractal dimension: -0.0693
perimeter error: 0.0631
mean smoothness: -0.0518
compactness error: -0.0504
radius error: 0.0467
concave points error: -0.0187
symmetry error: -0.0182
worst area: -0.0171
mean fractal dimension: -0.0157
mean area: -0.0138
smoothness error: -0.0048
fractal dimension error: -0.0044
```

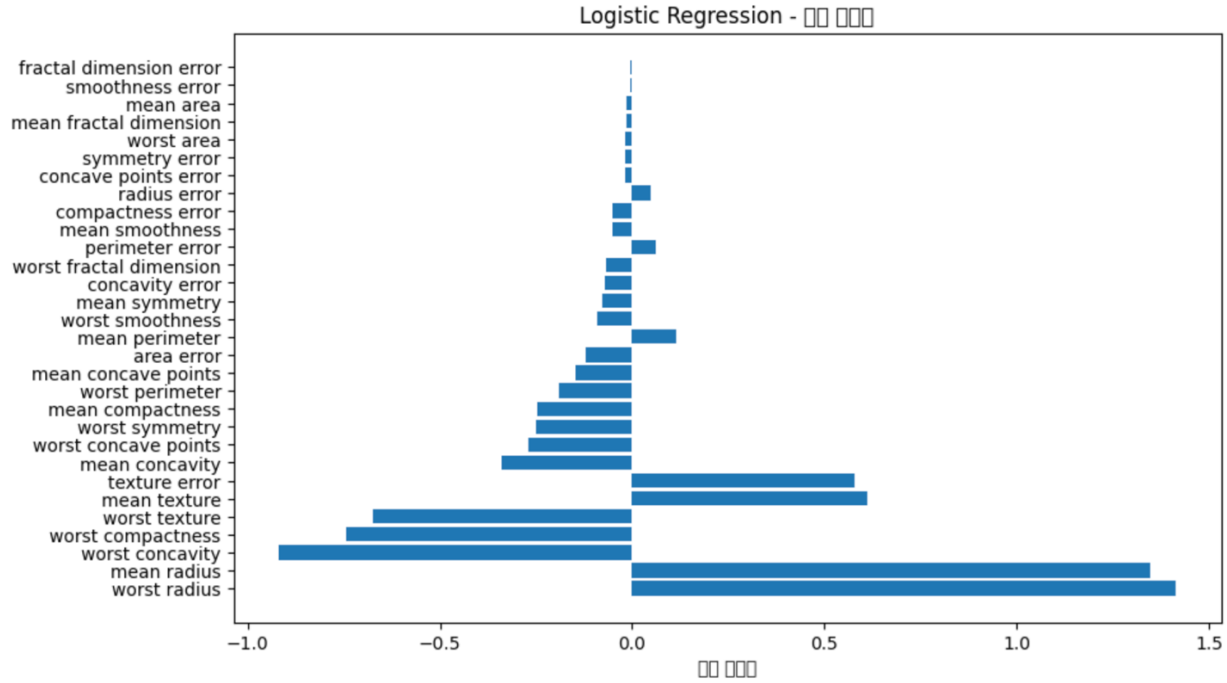

위 그래프를 보면 가장 큰 영향을 미치는 feature 가 worst radius 라는 것을 확인할 수 있다.